1. Indicaciones

- En esta actividad se evalúa si el estudiante *Criterio 3.1: Aplica modelos de aprendizaje no supervisado en casos prácticos complejos, analizando los resultados y proponiendo mejoras basadas en métricas de rendimiento.*

2. Descripción

Ecuador y sus residuos: descubrir perfiles de gestión municipal

La gestión de residuos combina recolección, barrido, separación y disposición final. Comparar municipios exige considerar sus diferencias de escala y la información que efectivamente reportan. El reto consiste en descubrir perfiles de gestión a partir de datos públicos y explicar qué necesidades de apoyo podrían explorarse para cada perfil.

Pregunta esencial

¿Qué perfiles de gestión de residuos aparecen en los registros municipales del Ecuador y cómo comunicar sus diferencias para orientar preguntas y propuestas de mejora?

Base de datos y acceso

Se utilizará exclusivamente la edición 2024 de la **Estadística de Información Ambiental Económica en GAD Municipales: Gestión de Residuos Sólidos**, publicada por el INEC. El archivo `BDD_GIRS_2024_VF.csv` contiene 221 registros y 213 columnas; no se utilizarán todas para agrupar. El separador es punto y coma y los decimales usan coma; la codificación Windows-1252 permite leer los nombres con tildes. Conservar `CantonId` como texto para no perder ceros iniciales.

- Portal oficial: sección Gestión Integral de Residuos Sólidos; descargar la base CSV, el diccionario, el formulario y la guía de uso correspondientes a esa edición.
- Descarga oficial de la base CSV comprimida.
- Catálogo y descripción de variables: contrastar los nombres y las definiciones con los archivos descargados.

Registrar fuente, edición, nombre del archivo y fecha de descarga en el notebook. Si cambia un enlace, localizar el recurso desde el portal sin sustituir silenciosamente la edición. La fecha de referencia de los datos no es una fecha de entrega.

Rol y productos

Actúas como parte de un equipo de análisis que prepara una nota para técnicos municipales. Entregarás un notebook reproducible en Colab y un informe divulgativo que explique los perfiles, sus límites y propuestas de mejora fundamentadas. No se busca entrenar un clasificador ni construir una clasificación oficial de municipios.

Preguntas guía

- ¿Los grupos reflejan prácticas de gestión o principalmente el tamaño de las operaciones?
- ¿Qué diferencias hay entre cero, dato faltante y pregunta que no aplica?
- ¿Qué cambia al usar cantidades absolutas frente a indicadores relativos?
- ¿Qué características distinguen a los grupos y qué municipios quedan poco representados por su perfil?
- ¿Qué conclusiones permanecen al cambiar el número de grupos o la inicialización?

Actividades guía

1. **Auditar los datos:** verificar la unidad de observación, los identificadores únicos, los duplicados, los tipos, las unidades y la disponibilidad de información. No mezclar ediciones ni incorporar totales como si fueran municipios.
2. **Elegir características:** proponer entre 4 y 8 variables numéricas o indicadores derivados, priorizando cobertura y pertinencia. Para cada característica, registrar código original, definición, unidad, transformación y motivo de inclusión. No completar el número de características con variables redundantes o con escasa información.
3. **Preparar la matriz:** tratar faltantes y valores no aplicables según el diccionario; revisar atípicos y escalas. No convertir categorías codificadas en números en cantidades continuas. Reservar identificadores y categorías para describir los grupos, sin incluirlos en las distancias.
4. **Evitar duplicar información:** no incluir simultáneamente un total y todos sus componentes sin justificar su peso. Construir proporciones solo con denominadores válidos y unidades compatibles; no inventar población ni otros denominadores ausentes de la base.
5. **Comparar agrupamientos:** aplicar K-Means y agrupamiento jerárquico sobre la misma matriz preparada, comparar al menos tres valores de k entre 2 y 6 y justificar el enlace y la distancia del método jerárquico. Si se usa Ward, emplear distancia euclidiana.
6. **Evaluar:** comparar silueta, tamaños de grupos e interpretación sustantiva. Revisar varias inicializaciones de K-Means con semillas registradas y discutir si cambian las conclusiones. No elegir una solución únicamente porque maximiza una métrica o produce una figura atractiva.

7. **Visualizar con PCA:** reportar varianza explicada individual y acumulada, representar los grupos en dos componentes e interpretar las variables que más contribuyen a ellas. Calcular las métricas en la matriz usada para agrupar, no en la proyección destinada solo a visualizar.

8. **Comunicar:** caracterizar cada grupo con tamaños y valores en unidades originales; asignar nombres descriptivos y proponer acciones vinculadas a sus características, señalando qué información adicional se necesita.

Pistas para la selección de características

Como punto de partida, revisar `VB` (vías barridas), `CSB` (cobertura del servicio de barrido), `CRR` (residuos recolectados, toneladas/mes), `TROT` (orgánicos tratados, toneladas/mes) y `RI` (inorgánicos recuperados, kg/mes). Son candidatas, no una selección obligatoria: comprobar sus unidades y justificar su uso antes de agrupar.

- `CSB` tiene cinco valores vacíos y cuatro superiores a uno; investigar y justificar su tratamiento, sin recortar automáticamente a uno.
- `TROT` y `RI` contienen muchos ceros; distinguir ausencia de actividad reportada de falta de información según el formulario.
- Las variables de composición, como `PORG`, tienen información en 108 municipios; incluirlas puede cambiar considerablemente el conjunto analizado.
- `RI` y `RIR` representan recuperación de inorgánicos en unidades distintas; no incluir ambas como características independientes.
- El diccionario presenta diferencias entre kg/año y kg/mes en campos como `MR4441`; no usar campos de unidad ambigua sin resolver y documentar esa discrepancia.
- `Pob` está descrita como población urbana proyectada con referencia a 2022; no asumir que representa la población cantonal total de 2024 ni usarla como denominador de todo el servicio municipal.

Requisitos y decisiones del equipo

Es obligatorio entregar ambos productos, justificar la preparación, comparar los dos algoritmos para al menos tres valores de k, presentar silueta y tamaños, discutir varias inicializaciones de K-Means e interpretar PCA. El equipo decide las características concretas, su tratamiento, los valores de k dentro del rango indicado y la solución final, justificando esas decisiones. Las variables sugeridas y los tipos de gráficos son orientaciones; la rúbrica mantiene las puntuaciones de cada apartado.

Alcance de las conclusiones

El análisis es exploratorio sobre los registros de una edición. No requiere una partición supervisada de entrenamiento y prueba, pues no se evalúa predicción de etiquetas; esto no elimina la necesidad de discutir estabilidad y limitaciones. Los grupos no

son una medición causal, un ranking de desempeño ni evidencia suficiente para asignar recursos. No eliminar municipios atípicos solo para mejorar la silueta. No reconstruir identificaciones eliminadas por la fuente ni elaborar mapas si la información pública no permite una correspondencia territorial verificable.

Hitos de seguimiento

Las fechas de envío, seguimiento y entrega se consultan en el cronograma y el aula virtual.

Hito 1. Auditoría inicial y propuesta de características con plan justificado de preparación.

Hito 2. Matriz preparada y propuesta de comparación de los dos algoritmos y PCA.

Hito 3. Borrador con tabla comparativa, perfiles, visualizaciones y discusión de estabilidad.

Hito 4. Entrega final del notebook y del informe divulgativo.

Producto

2.1 Jupyter Notebook

Usar el formato base y organizar el notebook para trabajar en Colab:

1. **Título y objetivos:** equipo, pregunta de análisis y alcance.
2. **Fuente y exploración:** instrucciones de carga del CSV, edición, dimensiones observadas, auditoría y diccionario de las características elegidas.
3. **Preparación:** decisiones sobre unidades, faltantes, atípicos, indicadores y escalado, indicando cuántos registros se conservan y por qué.
4. **Agrupamiento:** configuraciones, semillas, métricas, tamaños y comparación de los dos métodos para los valores de k elegidos.
5. **PCA:** varianza explicada, contribuciones de variables y proyección coloreada por grupo, distinguiendo visualización de evaluación.
6. **Interpretación:** tabla de perfiles en unidades originales, ejemplos de registros y discusión de estabilidad.
7. **Conclusiones:** respuesta a la pregunta, limitaciones y propuestas fundamentadas.

2.2 Informe divulgativo

Dirigir el informe a técnicos municipales, usando el formato de tareas PUCE en LaTeX.

1. **Introducción:** problema, fuente y alcance del análisis.
2. **Metodología:** explicación accesible de la preparación, el agrupamiento y PCA.

3. **Resultados:** perfiles descriptivos con tamaños y gráficos comprensibles, sin presentar los números de grupo como un orden de calidad.
4. **Implicaciones:** oportunidades de mejora por perfil y evidencia que las sustenta.
5. **Recomendaciones:** propuestas específicas con límites y necesidades de información adicional.
6. **Conclusión:** hallazgos principales y precauciones para su uso.

3. Rúbrica de evaluación

Jupyter Notebook (30 puntos totales)

1. **Título y descripción inicial (2 puntos)**
   - Introducción que contextualiza el problema y los objetivos (1 punto).
   - Breve descripción de las técnicas utilizadas (1 punto).
2. **Carga y descripción de datos (4 puntos)**
   - Descripción de las variables relevantes, análisis exploratorio básico (3 puntos).
   - Identificación y representación gráfica adecuada de distribuciones (1 punto).
3. **Preprocesamiento de datos (5 puntos)**
   - Limpieza de datos correctamente implementada (3 puntos).
   - Justificación clara de las decisiones tomadas en el preprocesamiento (2 puntos).
4. **Análisis con clustering (8 puntos)**
   - Implementación adecuada de al menos dos algoritmos de clustering (4 puntos).
   - Visualizaciones técnicas que representen los resultados (2 puntos).
   - Explicación de la calidad de los clusters obtenidos (2 puntos).
5. **Reducción de dimensiones (4 puntos)**
   - Implementación de una técnica de reducción de dimensiones (2 puntos).
   - Visualizaciones técnicas en 2D o 3D que resalten patrones clave (2 puntos).
6. **Interpretación de resultados (2 puntos)**
   - Discusión clara de los clusters formados y los patrones identificados (1.5 puntos).
   - Relación de los resultados con el problema inicial (0.5 puntos).
7. **Conclusión técnica (2 puntos)**
   - Resumen conciso de los hallazgos técnicos (1.5 puntos).
   - Identificación de limitaciones y posibles mejoras (0.5 puntos).

8. **Legibilidad y simpleza del código (3 puntos)**
   - Código bien comentado, organizado en secciones claras (1.5 puntos).
   - Uso de celdas Markdown para explicar los pasos (1.5 puntos).

Informe Divulgativo (20 puntos totales)

1. **Introducción (3 puntos)**
   - Contextualiza el problema y la relevancia del análisis (2 puntos).
   - Explica claramente los objetivos de la investigación (1 punto).
2. **Metodología (2 puntos)**
   - Breve descripción de las técnicas utilizadas (1.5 puntos).
   - Explicación de cómo estas técnicas ayudan a entender los datos (0.5 puntos).
3. **Resultados principales (5 puntos)**
   - Explicación de los clusters encontrados y sus características (2.5 puntos).
   - Uso de gráficos comprensibles y relevantes para el público objetivo (2.5 puntos).
4. **Implicaciones prácticas (3 puntos)**
   - Relación de los resultados con acciones concretas (2 puntos).
   - Interpretación de patrones significativos y su importancia (1 punto).
5. **Recomendaciones (2 puntos)**
   - Propuestas claras y aplicables basadas en los resultados del análisis (2 puntos).
6. **Conclusión (3 puntos)**
   - Resumen breve y relevante de los hallazgos (2 puntos).
   - Importancia de los resultados para la resolución del problema (1 punto).
7. **Presentación y diseño (2 puntos)**
   - Diseño profesional y organizado con secciones bien definidas (1 punto).
   - Uso de gráficos y tablas adecuadamente formateados (1 punto).