Actividad previa

- Revisar conjuntos de datos seleccionados por los estudiantes y brindar retroalimentación.
- Explicación de la distancia de Mahalanobis.

Resultado de Aprendizaje

RdA de la asignatura:

- **RdA 1:** Plantear los conceptos fundamentales del aprendizaje automático, incluyendo los principios básicos, técnicas de preprocesado de datos, métodos de evaluación y ajuste de modelos, destacando su importancia en el análisis y resolución de problemas de datos.

RdA de la clase:

- Comprender las técnicas principales de preprocesado de datos: escalado, discretización y reducción de dimensionalidad.
- Aplicar división de conjuntos de datos en entrenamiento y prueba para evaluar modelos de aprendizaje automático.
- Construir un flujo reproducible de preprocesamiento y partición, ajustando las transformaciones solo con los datos de entrenamiento para evitar fuga de información.

Introducción

Pregunta inicial:

- Si en un modelo una de las variables, por ejemplo, la edad, tiene un rango de valores entre 0 y 100, y otra variable, por ejemplo, el ingreso anual, tiene un rango entre $0 y $100000, ¿qué problemas podrían surgir al calcular distancias entre puntos en este espacio de características?
- ¿Si en un examen de matemática te evalúan con exactamente los mismos ejercicios que practicaste, qué tan bien crees que mediría tu conocimiento real de la materia?

Sesión 1: Partición de datos

Actividad 1: Conjuntos de Entrenamiento y Test

En esta actividad se abordará la importancia de dividir un conjunto de datos en entrenamiento y prueba mediante exploración de cuaderno de Jupyter.

¿Cómo lo haremos?

- **Métodos de partición:** Se presentará la necesidad de particionar conjuntos de datos, distinguiendo una variable objetivo continua de las clases de un problema de clasificación. Discutir cuándo conviene estratificar y por qué no hacerlo directamente con el precio continuo del ejemplo.
- **Flujo reproducible y prevención de fuga de información:** Se distinguirá entrenamiento para ajustar el modelo, validación para tomar decisiones y prueba para la evaluación final. Las transformaciones se ajustan solo con entrenamiento y se aplican a validación o prueba sin volver a ajustarlas. El cuaderno muestra la partición; la conexión con el preprocesamiento se discutirá en la siguiente sesión.
- **Implementación en Python:** Los estudiantes accederán a un cuaderno de Jupyter previamente preparado.

  Enlace al cuaderno: 03-2-Conjuntos-Entrenamiento-Prueba.ipynb.
- **Experimentación:** Resolver los ejercicios del cuaderno y registrar en una tabla la proporción de prueba, la semilla y los tamaños obtenidos; acompañarla de una conclusión sobre los cambios observados en la distribución del precio.

Cierre de la sesión: Explicar por qué usar prueba para elegir modelos afecta la evaluación final y dibujar una partición que incluya validación.

Para la siguiente sesión: Documentar las características, la variable objetivo y una propuesta justificada de partición del conjunto seleccionado.

Sesión 2: Preparación de datos

Conexión con la sesión anterior: Las transformaciones del cuaderno sobre Iris completo son demostraciones exploratorias; para evaluar un modelo supervisado, separar primero los datos y aprender los parámetros del preprocesamiento únicamente de entrenamiento. Recuperar PCA como conocimiento previo.

Actividad 2: Preprocesado de Datos

En esta actividad los estudiantes aprenderán las técnicas básicas de preprocesado de datos mediante clase magistral y práctica en cuaderno de Jupyter, incluyendo escalado, discretización y reducción de dimensionalidad para preparar datos de aprendizaje automático.

¿Cómo lo haremos?

- **Conceptos fundamentales:** Se presentarán las técnicas de preprocesado: escalado, discretización, one-hot-encoding y reducción de dimensionalidad.
- **Materiales de apoyo:** Se utilizará el documento Resumen03.pdf
- **Implementación en Python:** Los estudiantes accederán a un cuaderno de Jupyter previamente preparado.

  Enlace al cuaderno: 03-1-Procesado-Datos.ipynb.
- **Experimentación:** Resolver los ejercicios del cuaderno y comparar los resultados al cambiar la muestra y el número de intervalos; guardar una tabla o figura acompañada de una conclusión sobre la transformación aplicada.

Cierre

Verificación de aprendizaje:

1. ¿Por qué un valor nuevo puede quedar fuera de $[0, 1]$ tras aplicar Min-Max y por qué estandarizar no fija un rango?
2. ¿Cuál es la diferencia entre discretizar una variable usando igual amplitud o igual frecuencia?
3. ¿Qué información se filtra si calculas las escalas antes de separar entrenamiento y prueba?

Preguntas tipo entrevista:

1. Describe la diferencia entre discretización y one-hot encoding.
2. Un compañero afirma que toda columna numérica debe estandarizarse, incluidos los códigos de categorías: identifica el error y explica cómo decidir su tratamiento según su significado.

Tarea: Subir al repositorio un notebook con la fuente y descripción del conjunto seleccionado, una propuesta de partición y la justificación del preprocesamiento. Para el flujo supervisado, ajustar las transformaciones con entrenamiento y aplicar esos mismos parámetros a los otros conjuntos; no publicar datos cuya redistribución no esté autorizada.

Pregunta de investigación:

1. ¿Qué estrategias existen para manejar conjuntos de datos desbalanceados al realizar particiones de entrenamiento y prueba?
2. ¿Realizar one-hot encoding agrega colinealidad a las características? Ver: The Problem With One-Hot Encoding

Para la próxima clase: Tener disponible el notebook y las instrucciones de acceso a los datos, distinguiendo los datos originales, la partición y las transformaciones aprendidas de entrenamiento.