Facultad de Ciencias Exactas, Naturales y Ambientales
Ciencia de Datos • Aprendizaje Automático Inicial

Clase 04: Mi primer modelo

Andrés Merino • Periodo 2026-2

Actividad previa

- Recuperar la separación entre características y variable objetivo y la diferencia entre entrenamiento y prueba.
- Revisar las decisiones de preprocesamiento de la clase anterior, recordando que sus parámetros se aprenden solo de entrenamiento.

Resultado de Aprendizaje

RdA de la asignatura:

- **RdA 2:** Aplicar modelos de aprendizaje automático supervisado y no supervisado, así como su validación y optimización, en la resolución de problemas tanto reales como simulados.
- **RdA 3:** Resolver problemas prácticos mediante el uso de modelos de aprendizaje automático, ajustándolos para la mejora de su rendimiento y precisión.

RdA de la clase:

- Identificar las etapas esenciales del flujo de trabajo del entrenamiento de un modelo supervisado.
- Implementar la división de un conjunto de datos en entrenamiento y prueba mediante Python.
- Entrenar un modelo de regresión lineal e interpretar su error en datos de prueba como primera aproximación a la evaluación.

Introducción

Pregunta inicial: ¿Cómo se aplica el aprendizaje supervisado para predecir valores continuos en un conjunto de datos usando Python?

Desarrollo

Actividad 1: El flujo de trabajo del aprendizaje supervisado

Esta actividad presenta los elementos fundamentales del flujo de trabajo: generación de datos, separación en conjuntos, entrenamiento y evaluación. Se desarrollará mediante clase magistral apoyada con ejemplos y discusión guiada.

¿Cómo lo haremos?

- **Presentación del flujo:** Se revisarán las etapas: definición del problema, elección de características y objetivo, división de los datos, preparación cuando sea necesaria, entrenamiento, predicción y evaluación.
- **Alcance del ejemplo:** La regresión lineal se usará para recorrer el flujo completo, sin desarrollar aquí su teoría. Entrenar significa estimar sus coeficientes con datos de entrenamiento; prueba permite observar el error en datos separados. Si se comparan alternativas para elegir una, se necesita validación y se reserva prueba para la evaluación final.
- **Discusión guiada:** Se plantearán preguntas para reflexionar sobre la importancia de cada etapa.

Actividad 2: Implementación en Python de un modelo de regresión lineal

La actividad se desarrollará mediante trabajo práctico guiado en Python, utilizando un conjunto de datos simulado.

¿Cómo lo haremos?

- **Implementación en Python:** Los estudiantes accederán a un cuaderno de Jupyter previamente preparado.

  Enlace al cuaderno: 04-Mi-primer-modelo.ipynb.

- **Entrenamiento y evaluación:** Identificar qué datos recibe `fit`, obtener predicciones con `predict` y calcular el error cuadrático medio (MSE) en prueba. Interpretarlo en unidades cuadradas de la variable objetivo, sin asumir que un valor aislado permite declarar que el modelo es bueno.
- **Experimentación:**
  - Cambiar la proporción de prueba manteniendo fija la semilla y registrar tamaños y MSE en una tabla; explicar que también cambian las observaciones evaluadas y que el conjunto simulado es pequeño.
  - Explicar por qué no se debe elegir la partición o la semilla que produzca el menor error de prueba.

Actividad 3: Taller de implementación

Los estudiantes iniciarán un modelo de regresión lineal usando scikit-learn, siguiendo los pasos aprendidos, sobre el conjunto de datos `kingCountyHouseData`. La práctica se completará como tarea y se retomará en el taller de implementación previsto en el cronograma.

¿Cómo lo haremos?

- **Desarrollo del taller:** Predecir `price` a partir de `bedrooms`, `bathrooms`, `sqft_living`, `sqft_lot` y `floors`, documentando la fuente y revisando tipos y faltantes. Separar los datos antes de ajustar cualquier transformación y usar la siguiente plantilla:

  Enlace al cuaderno: 01-Mi-segundo-modelo-Plantilla.ipynb.

- **Evidencia inicial:** Preparar una primera versión del notebook con características y objetivo, dimensiones de las particiones, modelo ajustado, tabla de valores reales y predichos y una interpretación breve del MSE.
- **Continuación del taller:** Retomar esa primera versión, verificar que el preprocesamiento se ajuste solo con entrenamiento y completar la interpretación del MSE y las limitaciones del modelo en la plantilla.
- **Seguimiento del Reto 1:** Revisar el hito 1 (auditoría inicial y propuesta de características) y el hito 2 (matriz preparada y plan de comparación de agrupamientos y PCA), registrando dudas y decisiones pendientes sin exigir resultados de técnicas aún no trabajadas en clase.
- **Soporte y guía:** El instructor revisará la secuencia de trabajo y las decisiones documentadas; no se exige probar transformaciones no vistas en clase.

Cierre

Verificación de aprendizaje:

- ¿Qué etapas conforman el flujo de trabajo del aprendizaje supervisado?
- ¿Cómo se divide un conjunto de datos en entrenamiento y prueba utilizando Python?
- ¿Qué hacen los métodos `fit()`, `transform()` y `predict()` en scikit-learn?
- ¿Por qué un error pequeño calculado sobre los datos de entrenamiento no demuestra que el modelo generalice?

Tarea: Completar las tareas «Repositorio de GitHub para tareas» y «Mi segundo modelo» del aula virtual, documentando las decisiones y las limitaciones del resultado.

Reflexión de cierre: Participar en el foro «¿Qué aprendí esta semana?» explicando una decisión del flujo que ahora puedas justificar y una duda que quede pendiente.