Facultad de Ciencias Exactas, Naturales y Ambientales
Ciencia de Datos • Aprendizaje Automático Inicial

Clase 06: Reducción de Dimensionalidad y Extracción de Características

Andrés Merino • Periodo 2026-2

Resultado de Aprendizaje

RdA de la asignatura:

- **RdA 1:** Plantear los conceptos fundamentales del aprendizaje automático, incluyendo los principios básicos, técnicas de preprocesado de datos, métodos de evaluación y ajuste de modelos, destacando su importancia en el análisis y resolución de problemas de datos.

RdA de la clase:

- Comprender la importancia de la selección y extracción de atributos en la construcción de modelos eficientes.
- Implementar métodos básicos como PCA y SVD para reducir dimensionalidad.
- Analizar aplicaciones de factorización de matrices no negativas en aprendizaje automático.

Introducción

Pregunta inicial: Si varias características de un conjunto de datos aportan información parecida, ¿qué ganaríamos y qué podríamos perder al resumirlas en menos dimensiones antes de analizar los datos?

Desarrollo

Actividad 1: Selección de Atributos

Se repasará brevemente la selección de atributos para distinguirla de la extracción de nuevas características antes de trabajar con PCA.

¿Cómo lo haremos?

- **Clase interactiva:** Los estudiantes usarán un modelo GPT para recuperar las ideas principales de la selección de atributos y contrastarlas con la extracción de características.

  Enlace al GPT: Tutor AA - Selección de Atributos

Actividad 2: Análisis de Componentes Principales (PCA)

Se utilizará un modelo GPT para recuperar conceptos de PCA y se dará prioridad a su aplicación e interpretación en el cuaderno de Jupyter.

¿Cómo lo haremos?

- **Clase interactiva:** Los estudiantes interactuarán con un modelo GPT diseñado para evaluar sus conocimientos en PCA.

  Enlace al GPT: Evaluador AA - PCA

- **Implementación en Python:** Los estudiantes accederán a un cuaderno de Jupyter previamente preparado.

  Enlace al cuaderno: 06-1-Reduccion-Dimensionalidad.ipynb.

- **Experimentación:** Compara distintos números de componentes mediante la varianza explicada y las cargas; justifica cuánta información conserva la representación elegida.

Actividad 3: Descomposición en Valores Singulares (SVD)

Se retomará la relación entre PCA y SVD con una explicación breve y un ejemplo del cuaderno de Jupyter. El resumen matemático quedará disponible para profundizar después de la sesión.

¿Cómo lo haremos?

- **Clase magistral:** Se presentará la factorización $A = U\Sigma V^T$ y se interpretará el papel de los valores singulares en una aproximación de menor dimensión.
- **Materiales de apoyo:** Se utilizará el documento Resumen06.pdf
- **Implementación en Python:** Los estudiantes accederán a un cuaderno de Jupyter previamente preparado.

  Enlace al cuaderno: 06-2-SVD.ipynb.

- **Experimentación posterior:** Amplía la matriz de preferencias con más usuarios y películas; compara qué información conserva una aproximación con distintos números de valores singulares.

Cierre

Verificación de aprendizaje:

1. Al reducir cuatro características a dos componentes con PCA, ¿qué información revisarías para decidir si la representación es suficiente?
2. ¿Qué diferencia hay entre conservar dos atributos originales y construir dos componentes principales?
3. Si conservas menos valores singulares al reconstruir una matriz, ¿qué esperas que ocurra con la información representada?
4. En el ejemplo de preferencias, ¿qué representan U, Σ y V^T?

Preguntas tipo entrevista:

1. Tienes un dataset con 1000 características y solo 100 muestras. ¿Por qué esto es problemático y cómo usarías PCA para abordarlo? ¿Cuántos componentes principales deberías retener?
2. Si PCA reduce las dimensiones de mi dataset de 100 a 10 características, ¿significa que las 90 características descartadas no eran importantes?

Tarea: Leer la introducción al artículo Non-negative Matrix Factorization: A Survey.

Pregunta de investigación:

1. ¿Qué precaución tomarías antes de aplicar e interpretar PCA sobre variables categóricas codificadas como números?
2. ¿Cómo cambia la aproximación de una matriz de preferencias al conservar uno, dos o más valores singulares?

Para la próxima clase:

- Ver el video APRENDIZAJE NO SUPERVISADO EN MACHINE LEARNING.