Definición 1: Aprendizaje Automático.
El Aprendizaje Automático (Machine Learning) es una subdisciplina de la Inteligencia Artificial que se centra en el desarrollo de algoritmos y modelos que permiten a las máquinas aprender a partir de datos sin ser explícitamente programadas para cada tarea específica.

1. Tipos de Aprendizaje

Definición 2: Aprendizaje Supervisado.
Sea $X \subseteq \mathbb{R}^n$ y $Y \subseteq \mathbb{R}$, al conjunto:

$$D = \{(x_i, y_i)\}_{i=1}^m, \quad x_i \in X,\ y_i \in Y,$$

se lo denomina conjunto de datos de entrenamiento, a los elementos (x_i, y_i) se los denomina **instancias** o ejemplos de entrenamiento, donde $x_i \in \mathbb{R}^n$ son las **características** de las instancias y $y_i \in Y$ son las **etiquetas** asociadas (variable objetivo). El **aprendizaje supervisado** busca determinar una función

$$f\colon \mathbb{R}^n \to \mathbb{R}$$

que aproxime la etiqueta y de una instancia $x \in \mathbb{R}^n$, es decir, $f(x) \approx y$.

Definición 3: Aprendizaje No Supervisado.
Sea $X \subseteq \mathbb{R}^n$, al conjunto:

$$D = \{x_i\}_{i=1}^m, \quad x_i \in X,$$

se lo denomina conjunto de datos de entrenamiento, a los elementos x_i se los denomina **instancias** o ejemplos de entrenamiento, donde $x_i \in \mathbb{R}^n$ son las **características** de las instancias. El **aprendizaje no supervisado** busca descubrir estructura en los datos sin utilizar etiquetas objetivo. En particular, el agrupamiento busca determinar una función

$$f\colon \mathbb{R}^n \to \{1, 2, \dots, k\}$$

que asigne a cada instancia $x \in \mathbb{R}^n$ un grupo o clúster.

2. Tipos de tareas

Definición 4: Clasificación.
La **clasificación** es una tarea de **aprendizaje supervisado** donde el conjunto de etiquetas es un conjunto finito y discreto.

Definición 5: Regresión.
La **regresión** es una tarea de **aprendizaje supervisado** donde el conjunto de etiquetas es un conjunto continuo.

Definición 6: Agrupamiento.
El **agrupamiento** es una tarea de **aprendizaje no supervisado** donde se busca agrupar las instancias en función de sus características.

2.1 Modelos principales

Métodos	**Supervis.**		**No super.**
	Clasificación	Regresión	Agrupamiento
k-NN	×	×	
SVM	×	×	
Árboles de decisión	×	×	
Redes neuronales	×	×	
Agrupamiento jerárquico			×
k-means			×
DBSCAN			×

3. Métricas

Definición 7.
Dado un conjunto X, una métrica o distancia es una función

$$d\colon X \times X \to \mathbb{R}$$

que cumple las siguientes propiedades para todo $x, y, z \in X$:

I. $d(x, y) \geqslant 0$ (no negatividad)

II. $d(x, y) = 0$ si y solo si $x = y$ (identidad)

III. $d(x, y) = d(y, x)$ (simetría)

IV. $d(x, z) \leqslant d(x, y) + d(y, z)$ (desigualdad triangular)

DEFINICIÓN 8: Distancia Euclidiana.

En $\mathbb{R}^n$, la **distancia euclidiana** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_2(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}.$$

DEFINICIÓN 9: Distancia de Manhattan.

En $\mathbb{R}^n$, la **distancia de Manhattan** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_1(x, y) = \sum_{i=1}^{n} |x_i - y_i|.$$

DEFINICIÓN 10: Distancia de Minkowski.

En $\mathbb{R}^n$, la **distancia de Minkowski** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_p(x, y) = \left(\sum_{i=1}^{n} |x_i - y_i|^p \right)^{1/p},$$

donde $p \geqslant 1$.

⚠ La distancia de Minkowski generaliza tanto la distancia euclidiana ($p = 2$) como la distancia de Manhattan ($p = 1$).

⚠ La distancia euclidiana puede representarse por medio del producto de matrices como:

$$d_2(x, y) = \sqrt{(x - y)^T (x - y)}.$$

DEFINICIÓN 11: Distancia de Mahalanobis.

En $\mathbb{R}^n$, dada una matriz de covarianza S simétrica y definida positiva, la **distancia de Mahalanobis** se define como:

$$d_M(x, y) = \sqrt{(x - y)^T S^{-1} (x - y)}.$$

⚠ Si la covarianza es singular, la inversa de la fórmula de Mahalanobis no existe. En un problema supervisado, estimar la covarianza solo con entrenamiento. Cambiar unidades o escalas también cambia las distancias euclidiana y de Manhattan.

DEFINICIÓN 12: Hamming.

En $\mathbb{R}^n$, la **distancia de Hamming** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y =$

$(y_1, y_2, \dots, y_n)$ se define como:

$$d_H(x, y) = \sum_{i=1}^{n} \delta(x_i, y_i),$$

donde

$$\delta(x_i, y_i) = \begin{cases} 0 & \text{si } x_i = y_i, \\ 1 & \text{si } x_i \neq y_i. \end{cases}$$

Es decir, cuenta el número de posiciones en las que los elementos correspondientes son diferentes.

DEFINICIÓN 13: Disimilitud coseno.

Para vectores no nulos de $\mathbb{R}^n$, la **disimilitud coseno** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_{cos}(x, y) = 1 - \frac{x \cdot y}{\|x\|\|y\|}.$$

⚠ La disimilitud coseno no es, en general, una métrica ni una pseudométrica: puede incumplir la desigualdad triangular. Además, vectores distintos con la misma dirección tienen disimilitud cero. Por ejemplo, para $x = (1, 0)$, $y = (1, 1)$ y $z = (0, 1)$, se tiene $d(x, z) = 1 > 2 - \sqrt{2} = d(x, y) + d(y, z)$. No está definida para el vector nulo.