

DEFINICIÓN 1: Aprendizaje Automático.

El Aprendizaje Automático (Machine Learning) es una subdisciplina de la Inteligencia Artificial que se centra en el desarrollo de algoritmos y modelos que permiten a las máquinas aprender a partir de datos sin ser explícitamente programadas para cada tarea específica.

1. TIPOS DE APRENDIZAJE

DEFINICIÓN 2: Aprendizaje Supervisado.

Sea $X \subseteq \mathbb{R}^n$ y $Y \subseteq \mathbb{R}$, al conjunto:

$$\{(x, y) : x \in X, y \in Y\},$$

se lo denomina conjunto de datos de entrenamiento, a los elementos (x_i, y_i) se los denomina **instancias** o ejemplos de entrenamiento, donde $x_i \in \mathbb{R}^n$ son las **características** de las instancias y $y_i \in Y$ son las **etiquetas** asociadas (variable objetivo). El **aprendizaje supervisado** busca determinar una función

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

que aproxime la etiqueta y de una instancia $x \in \mathbb{R}^n$, es decir, $f(x) \approx y$.

DEFINICIÓN 3: Aprendizaje No Supervisado.

Sea $X \subseteq \mathbb{R}^n$, al conjunto:

$$\{x : x \in X\},$$

se lo denomina conjunto de datos de entrenamiento, a los elementos x_i se los denomina **instancias** o ejemplos de entrenamiento, donde $x_i \in \mathbb{R}^n$ son las **características** de las instancias. El **aprendizaje no supervisado** busca determinar una función

$$f: \mathbb{R}^n \rightarrow \{1, 2, \dots, k\}$$

que asigne a cada instancia $x \in \mathbb{R}^n$ un grupo o clúster.

2. TIPOS DE TAREAS

DEFINICIÓN 4: Clasificación.

La **clasificación** es una tarea de **aprendizaje supervisado** donde el conjunto de etiquetas es un conjunto finito y discreto.

DEFINICIÓN 5: Regresión.

La **regresión** es una tarea de **aprendizaje supervisado** donde el conjunto de etiquetas es un conjunto continuo.

DEFINICIÓN 6: Agrupamiento.

El **agrupamiento** es una tarea de **aprendizaje no supervisado** donde se busca agrupar las instancias en función de sus características.

2.1 Modelos principales

Métodos	Supervis.		No super.
	Clasificación	Regresión	
k-NN	×		
SVM	×	×	
Árboles de decisión	×	×	
Redes neuronales	×	×	
Agrupamiento jerárquico			×
k-means			×
DBSCAN			×

3. MÉTRICAS

DEFINICIÓN 7.

Dado un conjunto X , una métrica o distancia es una función

$$d: X \times X \rightarrow \mathbb{R}$$

que cumple las siguientes propiedades para todo $x, y, z \in X$:

- I. $d(x, y) \geq 0$ (no negatividad)
- II. $d(x, y) = 0$ si y solo si $x = y$ (identidad)
- III. $d(x, y) = d(y, x)$ (simetría)
- IV. $d(x, z) \leq d(x, y) + d(y, z)$ (desigualdad triangular)

DEFINICIÓN 8: Distancia Euclíadiana.

En \mathbb{R}^n , la **distancia euclíadiana** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_2(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}.$$

DEFINICIÓN 9: Distancia de Manhattan.

En \mathbb{R}^n , la **distancia de Manhattan** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_1(x, y) = \sum_{i=1}^n |x_i - y_i|.$$

DEFINICIÓN 10: Distancia de Minkowski.

En \mathbb{R}^n , la **distancia de Minkowski** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_p(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p},$$

donde $p \geq 1$.



La distancia de Minkowski generaliza tanto la distancia euclíadiana ($p = 2$) como la distancia de Manhattan ($p = 1$).



La distancia euclíadiana puede representarse por medio del producto de matrices como:

$$d_2(x, y) = \sqrt{(x - y)^T (x - y)}.$$

DEFINICIÓN 11: Distancia de Mahalanobis.

En \mathbb{R}^n , dado un conjunto de datos con media μ y matriz de covarianza S , la **distancia de Mahalanobis** se define como:

$$d_M(x, y) = \sqrt{(x - y)^T S^{-1} (x - y)}.$$

DEFINICIÓN 12: Hamming.

En \mathbb{R}^n , la **distancia de Hamming** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_H(x, y) = \sum_{i=1}^n \delta(x_i, y_i),$$

donde

$$\delta(x_i, y_i) = \begin{cases} 0 & \text{si } x_i = y_i, \\ 1 & \text{si } x_i \neq y_i. \end{cases}$$

Es decir, cuenta el número de posiciones en las que los elementos correspondientes son diferentes.

DEFINICIÓN 13: Distancia Coseno.

En $\mathbb{R}_{\geq 0}^n$, la **distancia coseno** entre dos puntos $x = (x_1, x_2, \dots, x_n)$ y $y = (y_1, y_2, \dots, y_n)$ se define como:

$$d_{\cos}(x, y) = 1 - \frac{x \cdot y}{\|x\| \|y\|}.$$



La distancia coseno no es una métrica en el sentido estricto, ya que no cumple con la identidad; por esto se la llama una **pseudo-métrica**.