

## SUPPORT VECTOR MACHINE (SVM)

Vladimir Vapnik dijo: «No existe nada más práctico que una buena teoría».

### DEFINICIÓN 1.

Sea un conjunto de entrenamiento  $\{(x_i, y_i)\}_{i=1}^N$  donde  $x_i \in \mathbb{R}^n$  son los vectores de características y  $y_i \in \{-1, 1\}$  son las etiquetas de clase.

El modelo SVM busca determinar un hiperplano, definido por

$$w \cdot x + b = 0,$$


que separe los datos, es decir

$$w \cdot x_i + b \geq 1 \text{ si } y_i = 1 \quad \text{y} \quad w \cdot x_i + b \leq -1 \text{ si } y_i = -1.$$

La condición puede tomarse como:


$$y_i(w \cdot x_i + b) \geq 1$$

A los vectores que alcanzan la igualdad de la condición, es decir,  $y_i(w \cdot x_i + b) = 1$ , se los llama **vectores de soporte**.



La distancia de los vectores de soporte al hiperplano separador es  $m$  (margen). El objetivo es maximizar el margen, que es la distancia entre los hiperplanos por los que pasan los vectores de soporte:  $2m$ .

Para determinar el valor de  $t$ , consideremos momentáneamente que el hiperplano pasa por el origen (es decir,  $b = 0$ ).



La distancia  $m$  desde el punto  $x_i$  al hiperplano se puede calcular como la norma de la proyección del vector  $x_i$  sobre el vector normal al hiperplano  $w$ :

$$m = \|\text{proy}_w(x_i)\| = \left\| \frac{x_i \cdot w}{\|w\|^2} \cdot w \right\|,$$

además, como  $x_i$  está sobre el hiperplano de ecuación  $w \cdot x = 1$ , se cumple que  $w \cdot x_i = 1$ . Por lo tanto:

$$m = \left\| \frac{1}{\|w\|^2} \cdot w \right\| = \frac{1}{\|w\|}.$$

Con esto, lo que debemos maximizar es  $2m = \frac{2}{\|w\|}$ , lo cual es equivalente a minimizar  $\frac{1}{2}\|w\|$ ; por conveniencia, se minimiza el cuadrado de la norma. Así, el problema de optimización queda:

$$\begin{cases} \text{mín} & f(w, b) = \frac{1}{2}\|w\|^2 \\ \text{sujeto a} & \\ & y_i(w \cdot x_i + b) \geq 1, \quad i = 1, \dots, N \end{cases}$$

Para resolver este problema de optimización con restricciones, se utiliza el método de los multiplicadores de Lagrange. Planteamos el Lagrangiano usando multiplicadores de Lagrange  $\alpha_i \geq 0$ :

$$L(w, b, \alpha_1, \dots, \alpha_N) = \frac{1}{2}\|w\|^2 - \sum_{i=1}^N \alpha_i (y_i(w \cdot x_i + b) - 1),$$

desarrollando:

$$L(w, b, \alpha_1, \dots, \alpha_N) = \frac{1}{2}w \cdot w - w \cdot \sum_{i=1}^N \alpha_i y_i x_i - b \sum_{i=1}^N \alpha_i y_i + \sum_{i=1}^N \alpha_i.$$

Con esto, obtenemos las condiciones de optimalidad, derivando parcialmente el Lagrangiano con respecto a  $w$  y  $b$  e igualando a cero:

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^N \alpha_i y_i x_i$$

y

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \Rightarrow \sum_{i=1}^N \alpha_i y_i = 0.$$

Reemplazamos las condiciones de optimalidad en el Lagrangiano para obtener el problema dual:

$$L(w, b, \alpha_1, \dots, \alpha_N) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j).$$

El problema dual de maximización es:

$$\begin{cases} \text{máx} & L_D(\alpha_1, \dots, \alpha_N) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \\ \text{sujeto a} & \alpha_i \geq 0, \quad i = 1, \dots, N, \\ & \sum_{i=1}^N \alpha_i y_i = 0. \end{cases}$$

## 1. FUNCIONES KERNEL

### DEFINICIÓN 2.

Una función kernel es una función

$$K: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$$

que cumple las propiedades distributiva, conmutativa y semidefinida positiva.

Dada una función de mapeo

$$\phi: \mathbb{R}^n \rightarrow \mathbb{R}^m,$$



se define el kernel asociado como

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j).$$

Al usar funciones kernel, el problema dual de maximización queda:

$$\begin{cases} \text{máx} & L_D(\alpha_1, \dots, \alpha_N) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{sujeto a} & \alpha_i \geq 0, \quad i = 1, \dots, N, \\ & \sum_{i=1}^N \alpha_i y_i = 0. \end{cases}$$

Algunas funciones kernel comunes son:

- Kernel lineal:  $K(x_i, x_j) = x_i \cdot x_j$ .

- Kernel polinomial:  $K(x_i, x_j) = (\alpha x_i \cdot x_j + c)^p$ , con  $\alpha > 0$ ,  $c \geq 0$  y  $p \in \mathbb{N}$ .
- Kernel radial:  $K(x_i, x_j) = \exp\left(-\alpha \|x_i - x_j\|^2\right)$ , con  $\alpha > 0$ .